

# **Dự đoán nguy cơ đột quy.**

Present by: Duong Hieu - Le

Guided by: Assoc. Prof. Dr. Van Hau - Nguyen

# Table of contents

01

Introduce the problem

02

Modul

03

Processing and prediction

04

Result

01

# Introduce the problem

# Bệnh đột quy là gì?

Theo Tổ chức Y tế Thế giới (WHO), đột quy là nguyên nhân gây tử vong đứng thứ hai trên toàn cầu. Đây là một bệnh có tỷ lệ mắc bệnh, tàn tật và tử vong cao, trong đó các nạn nhân có thể đột ngột trải qua tình trạng liệt, suy giảm khả năng nói hoặc mất thị lực do sự gián đoạn dòng máu (thiếu máu cục bộ) gây ra bởi huyết khối và thuỷt tắc.

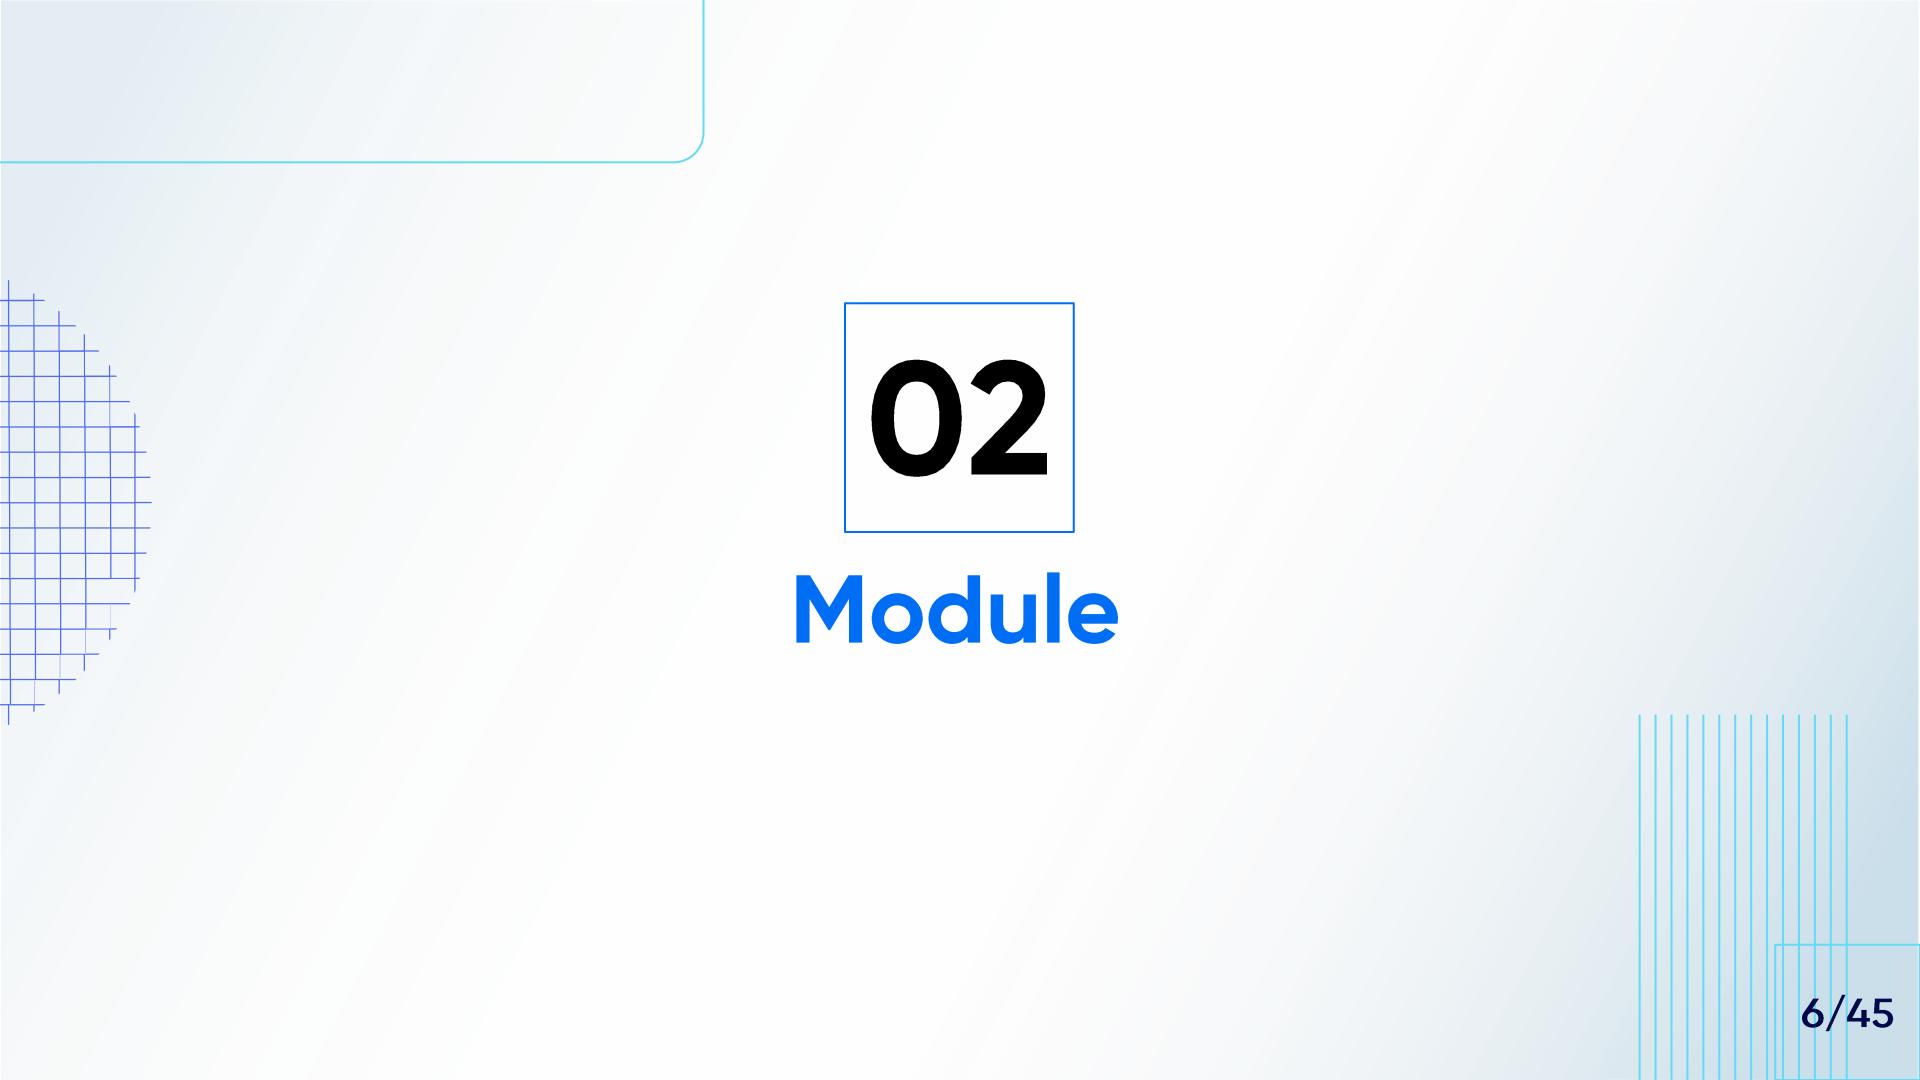
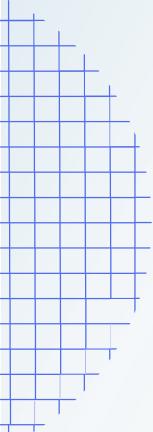


Hình 1: Minh họa bệnh đột quy [1]

# Lý do chọn đề tài



Hình 2: Thống kê số ca đột quy hàng năm tại Việt Nam [2]

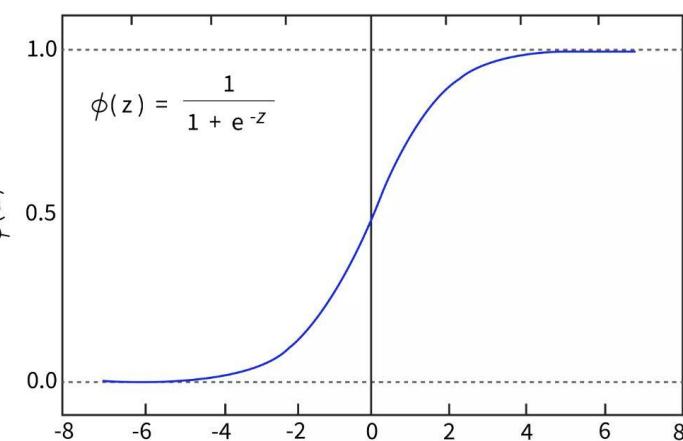


02

## Module

# Logistic Regression

Tham số	sklearn mặc định	Từ bài báo	Ghi chú
<b>penalty</b>	'l2'	'l2'	Giảm trọng số của các đặc trưng mà không loại bỏ chúng
<b>solver</b>	'lbfgs'	'liblinear'	Tối ưu hơn cho dữ liệu nhỏ & imbalance
<b>C</b>	1.0	1.0	Là quy chuẩn hóa mạnh hơn (phạt lớn hơn), buộc mô hình phải đơn giản hơn (giảm overfitting).
<b>class_weight</b>	None	'balanced'	Tự động tính trọng số tỷ lệ nghịch với tần suất lớp.
<b>max_iter</b>	100	200	Số lần lặp tối đa để thuật toán tối ưu hóa hội tụ
<b>random_state</b>	None	42	Để tái lập kết quả

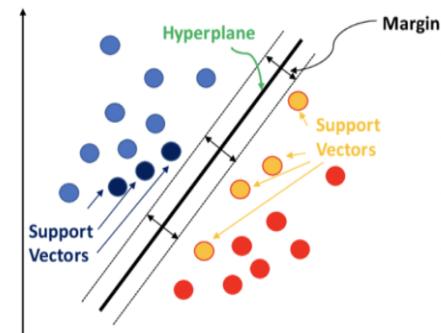


Hình 3: Thuật toán Hồi quy Logistic [3]

# Support Vector Machine

Tham số	sklearn mặc định	Từ bài báo	Ghi chú
<b>kernel</b>	'rbf'	'rbf'	Xử lý các quan hệ phi tuyến tính
<b>C</b>	1.0	10	Tăng độ phạt để tách lớp tốt hơn
<b>gamma</b>	'scale'	0.01	Gamma cố định nhỏ giúp ổn định trên imbalance
<b>class_weight</b>	None	'balance d'	Xử lý mất cân bằng lớp
<b>random_state</b>	None	42	Để tái lập kết quả

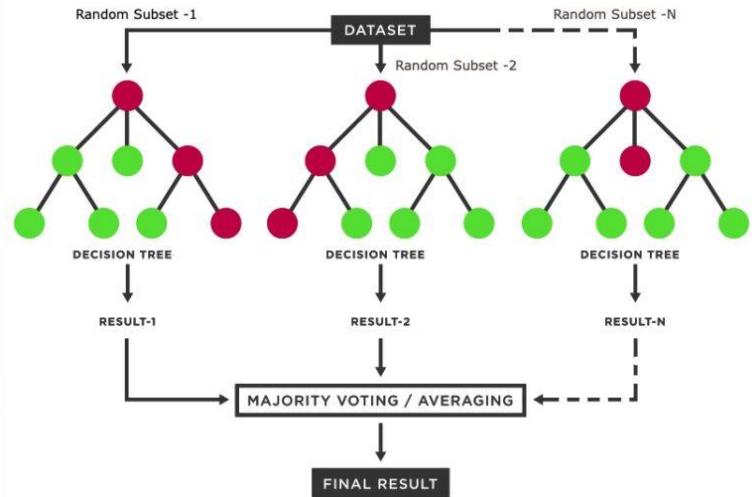
WHAT IS A  
**SUPPORT  
VECTOR  
MACHINE?**



Hình 4: Thuật toán Support Vector Machine [4]

# Random Forest

Tham số	sklearn mặc định	Từ bài báo	Ghi chú
<b>n_estimators</b>	100	300	Nhiều cây → ổn định hơn
<b>max_depth</b>	None	20	Tránh overfitting
<b>min_samples_split</b>	2	2	Số lượng mẫu tối thiểu cần thiết để một nút bên trong được phép chia.
<b>min_samples_leaf</b>	1	4	Giúp giảm noise lớp thiểu số
<b>max_features</b>	'sqrt'	'sqrt'	Số lượng đặc trưng tối đa được xem xét khi tìm kiếm sự phân chia tốt nhất tại một nút.
<b>class_weight</b>	None	'balanced_subsample'	Xử lý imbalance
<b>random_state</b>	None	42	Để tái lập

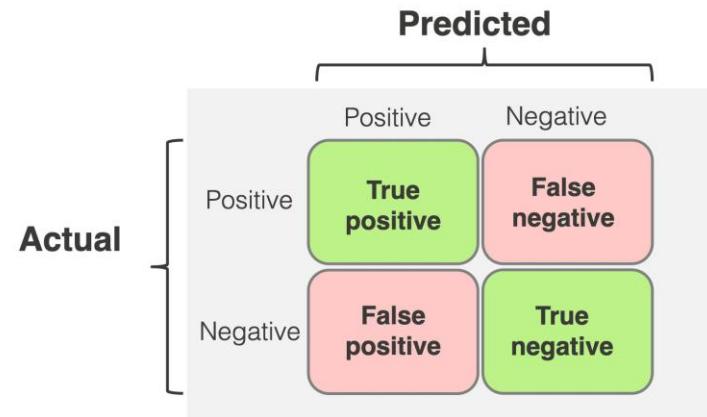


Hình 5: Thuật toán Random Forest [5]

# Phương pháp đánh giá

$$\text{Precision} = \frac{\text{TP}}{\text{TP} + \text{FP}}$$

$$\text{Recall} = \frac{\text{TP}}{\text{TP} + \text{FN}}$$



Hình 6: Ma trận nhầm lẫn [6]

03

# Processing and prediction

# Data

	id	gender	age	hypertension	heart_disease	ever_married	work_type	Residence_type	avg_glucose_level	bmi	smoking_status	stroke
0	30669	Male	3	0	0	No	children	Rural	95.12	18	NaN	0
1	30468	Male	58	1	0	Yes	Private	Urban	87.96	39.2	never smoked	0
2	16523	Female	8	0	0	No	Private	Urban	110.89	17.6	NaN	0
3	56543	Female	70	0	0	Yes	Private	Rural	69.04	35.9	formerly smoked	0
4	46136	Male	14	0	0	No	Never_worked	Rural	161.28	19.1	NaN	0
...	...	...	...	...	...	...	...	...	...	...	...	...
43399	36271	Female	82	0	0	Yes	Private	Urban	79.48	20.6	never smoked	0

Bảng 1: Dữ liệu

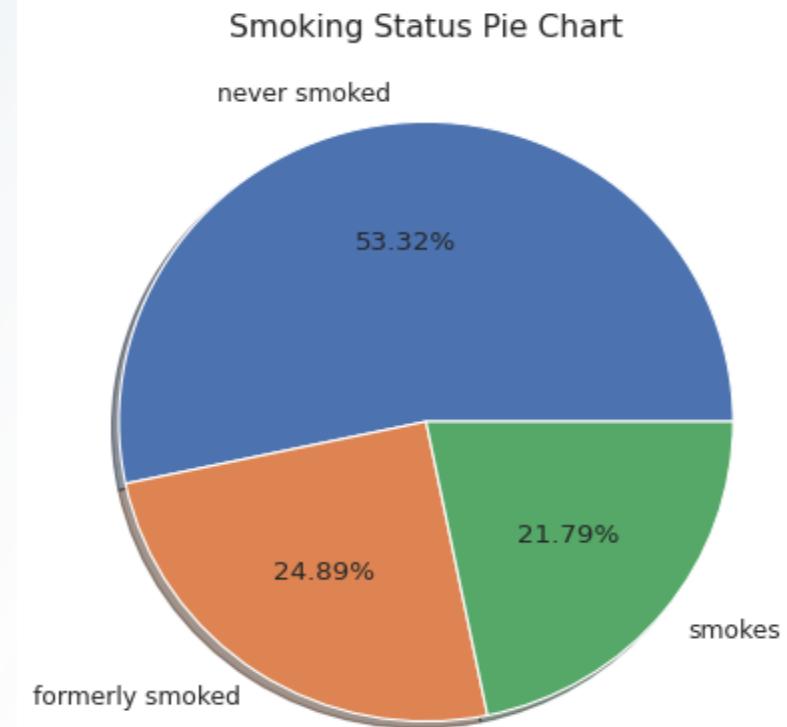
(43400,12)

# Dữ liệu của cột

Cột	Kiểu dữ liệu	Mục đích
id	int64	Mã định danh của từng bệnh nhân.
gender	object	Giới tính của bệnh nhân.
age	float64	Tuổi của bệnh nhân.
hypertension	int64	Cho biết liệu bệnh nhân có bị cao huyết áp hay không.
heart_disease	int64	Cho biết liệu bệnh nhân có mắc bệnh tim mạch hay không.
ever_married	object	Cho biết liệu bệnh nhân đã từng kết hôn hay chưa.
work_type	object	Loại công việc của bệnh nhân.
Residence_type	object	Loại nơi cư trú của bệnh nhân (thành thị hoặc nông thôn).
avg_glucose_level	float64	Mức đường huyết trung bình của bệnh nhân.
bmi	float64	Chỉ số khối cơ thể (Body Mass Index) của bệnh nhân.
smoking_status	object	Tình trạng hút thuốc của bệnh nhân.

Bảng 2: Kiểu dữ liệu của các Feature

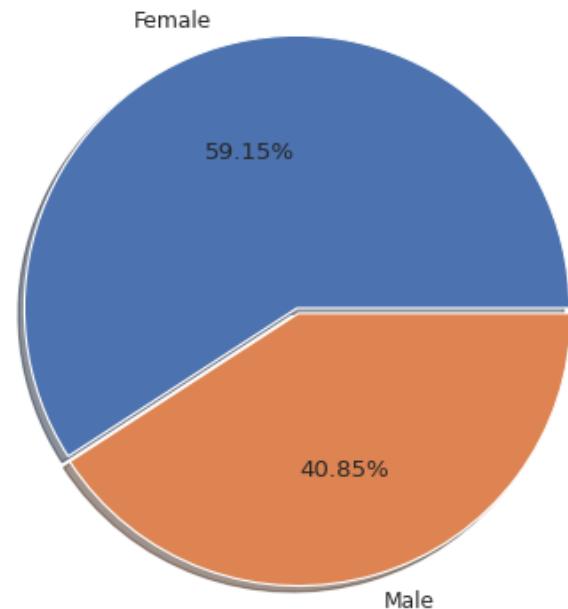
# Tương quan dữ liệu



Hình 7: Feature Smoking\_status

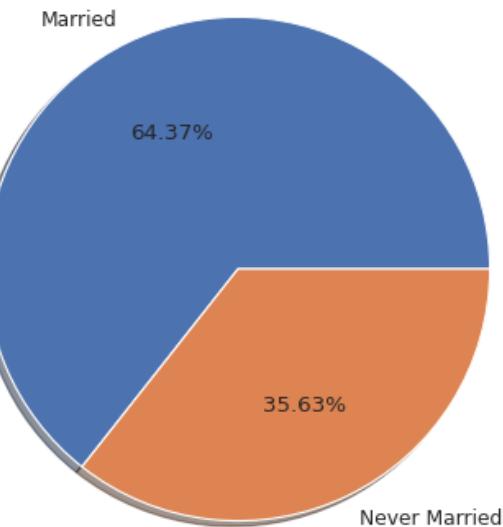
# Tương quan dữ liệu

Gender Distribution Pie Chart



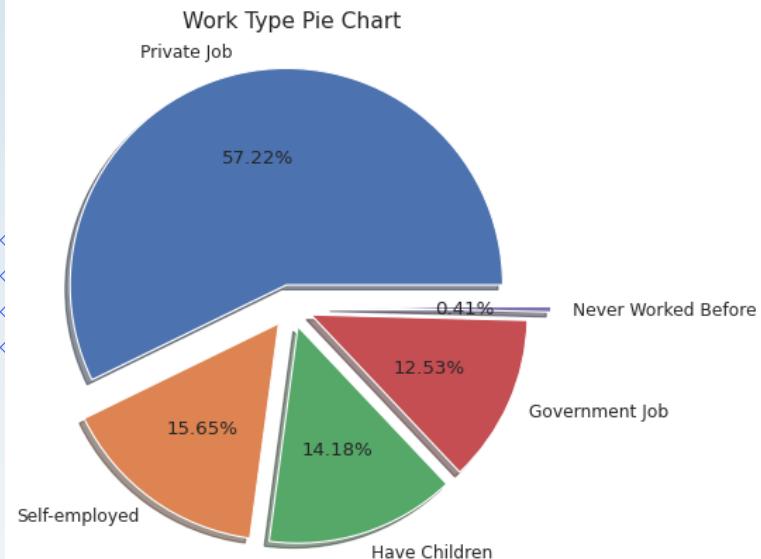
Hình 8: Feature Gender

Marital Status Pie Chart

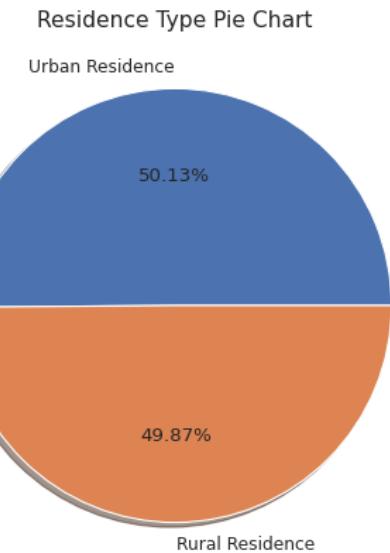


Hình 9: Feature Ever\_married

# Tương quan dữ liệu



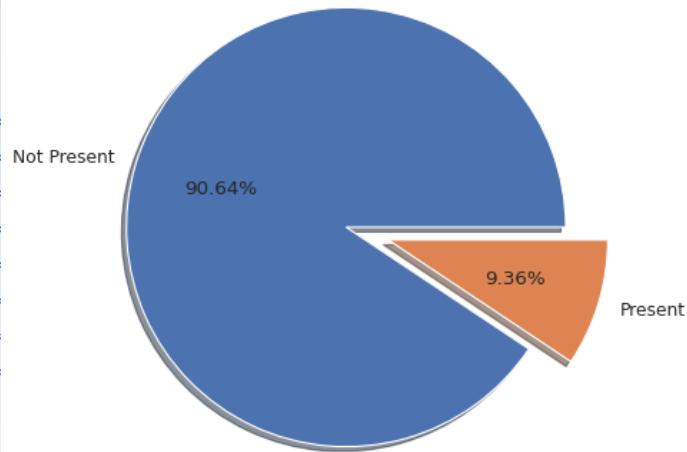
Hình 10: Feature Work\_type



Hình 11: Feature Residence\_type

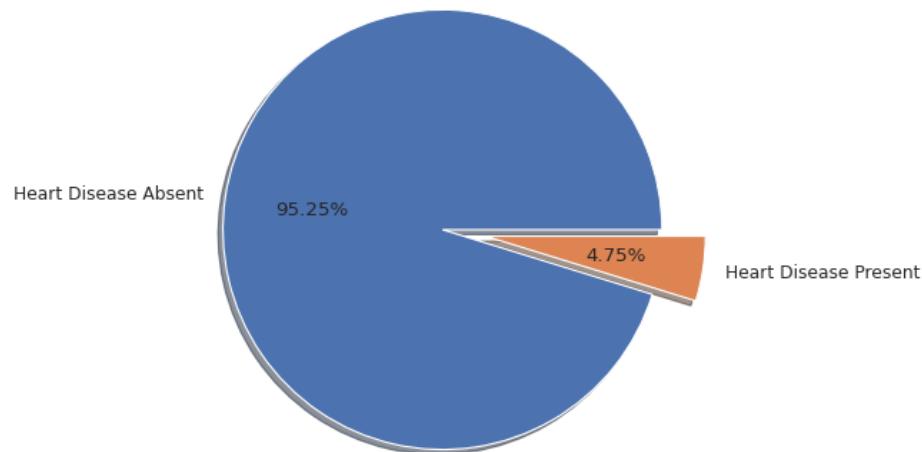
# Tương quan dữ liệu

Hypertension Distribution Pie Chart



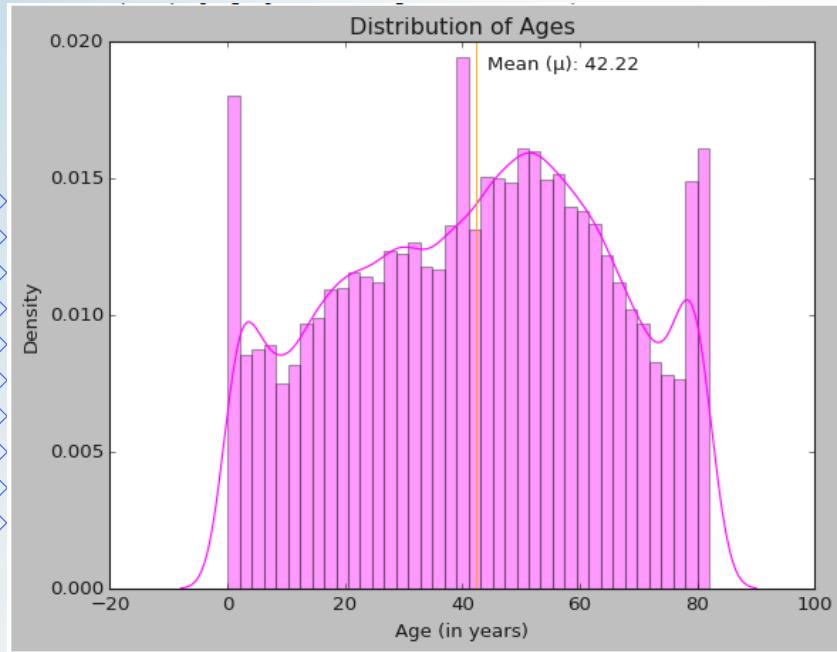
Hình 12: Feature Hypertension

Heart Disease Distribution Pie Chart

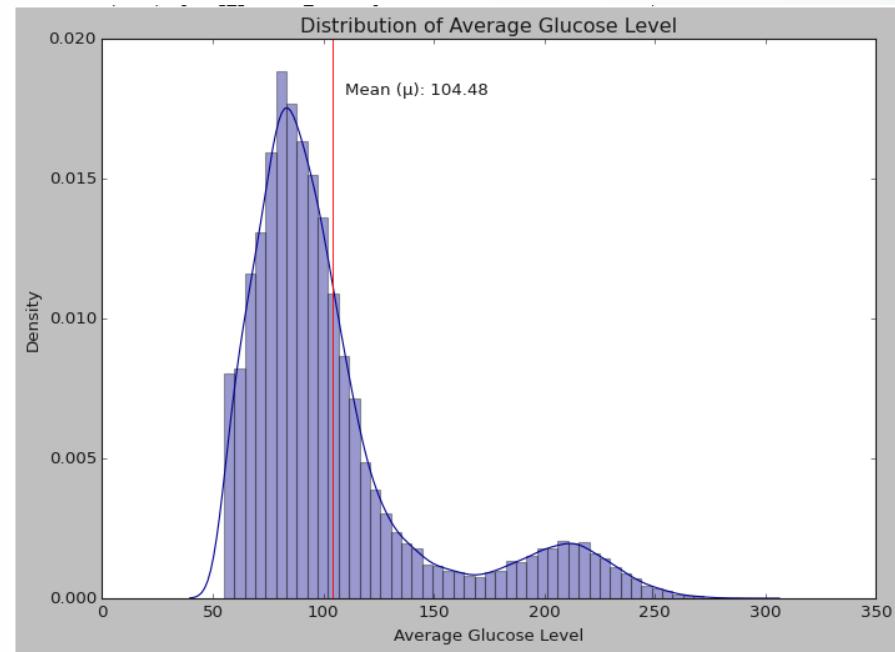


Hình 13: Feature Heart Disease

# Tương quan dữ liệu

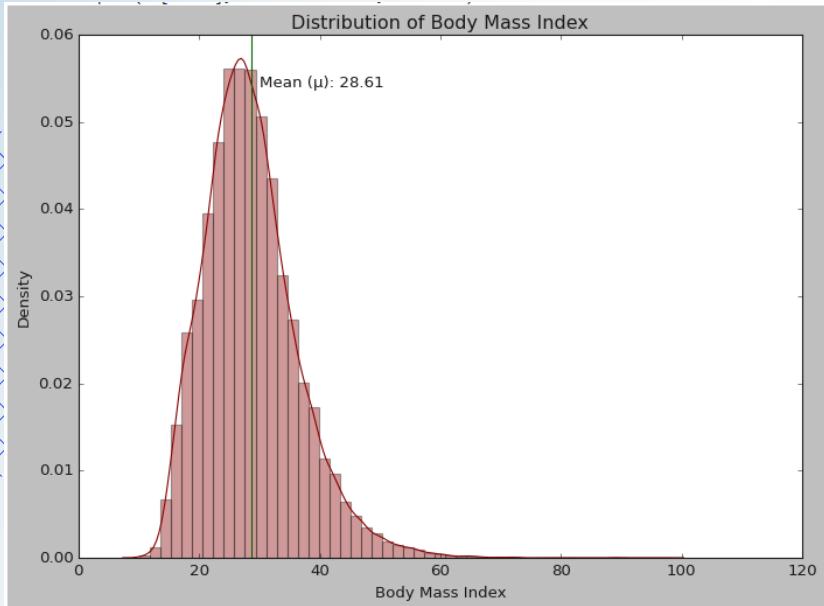


Hình 14: Feature Ages

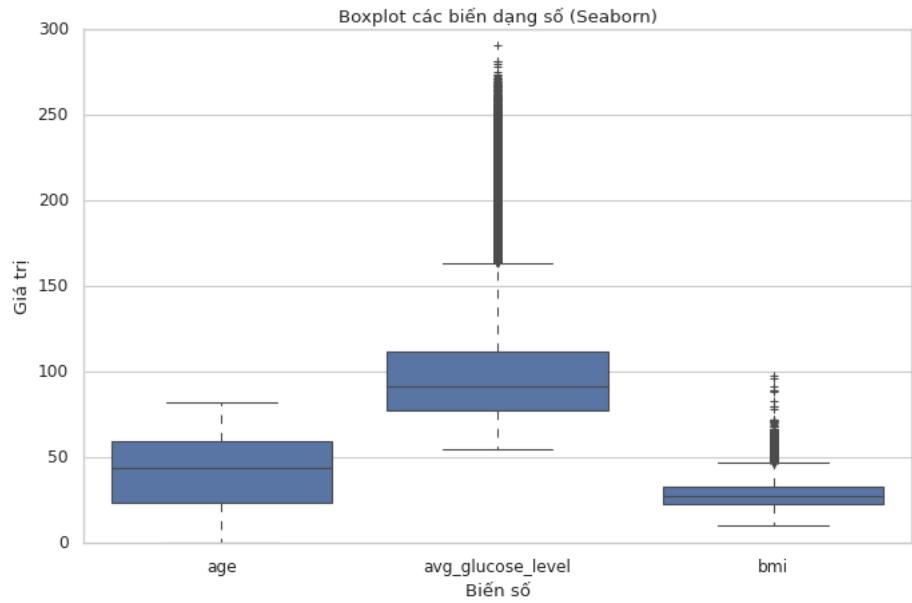


Hình 15: Feature Average Glucose

# Tương quan dữ liệu

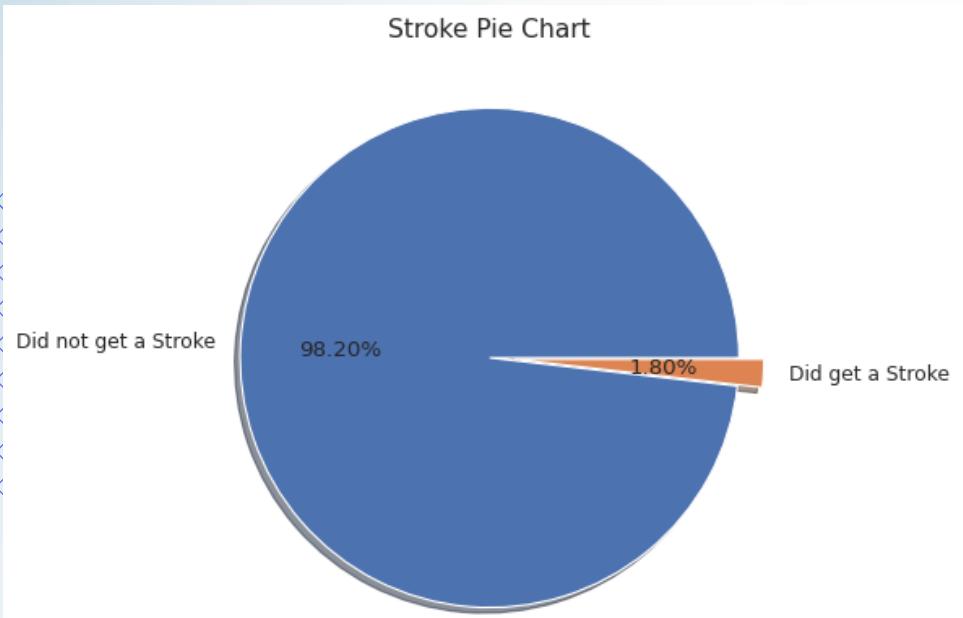


Hình 16: Feature BMI

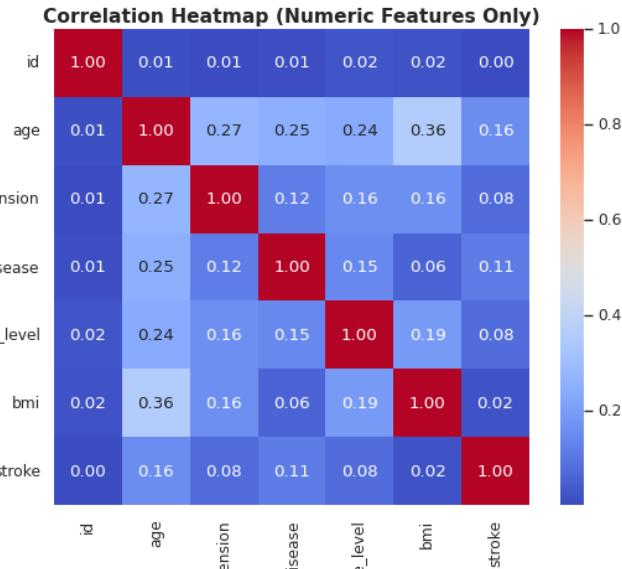


Hình 17: Boxplot

# Tương quan dữ liệu

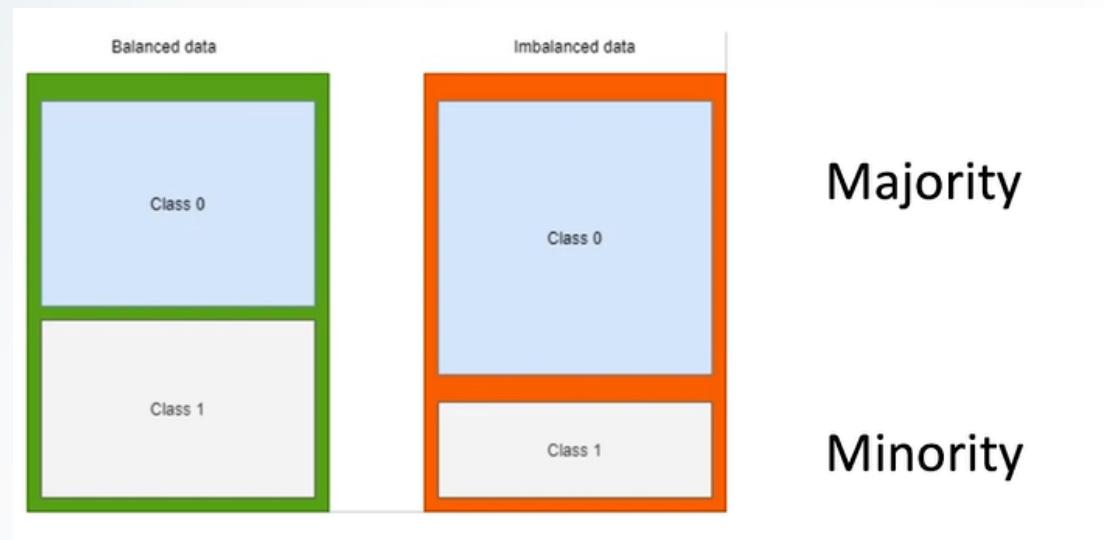


Hình 18: Lable



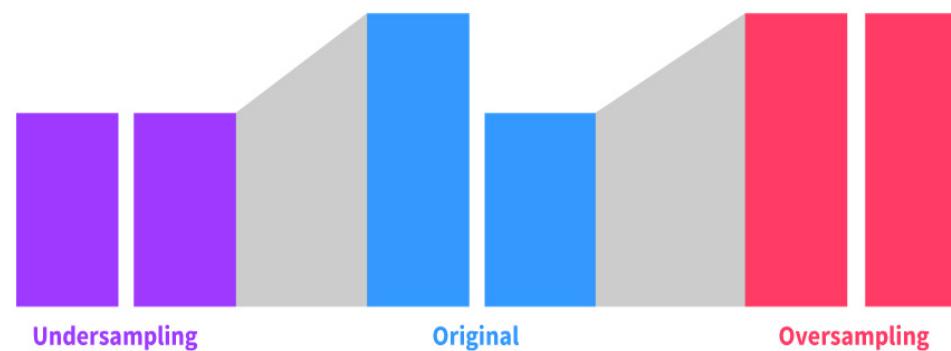
Hình 19: Heat map

# Vấn đề Imbalance



Hình 20: Các lớp trong dữ liệu Imbalance [7]

# Cách xử lý



Hình 21: Các cách xử lý dữ liệu Imbalance [8]

# Cách xử lý

## NearMiss-1:

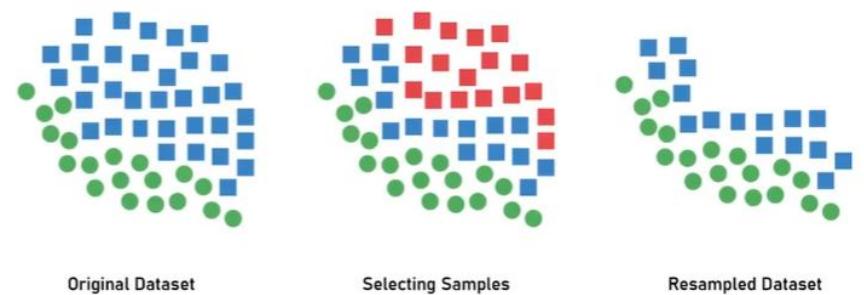
Các mẫu thuộc lớp đa số có khoảng cách trung bình nhỏ nhất tới ba mẫu gần nhất của lớp thiểu số.

## NearMiss-2:

Các mẫu thuộc lớp đa số có khoảng cách trung bình nhỏ nhất tới ba mẫu xa nhất của lớp thiểu số.

## NearMiss-3

Các mẫu thuộc lớp đa số có khoảng cách nhỏ nhất tới mỗi mẫu của lớp thiểu số.



Hình 22: Near miss

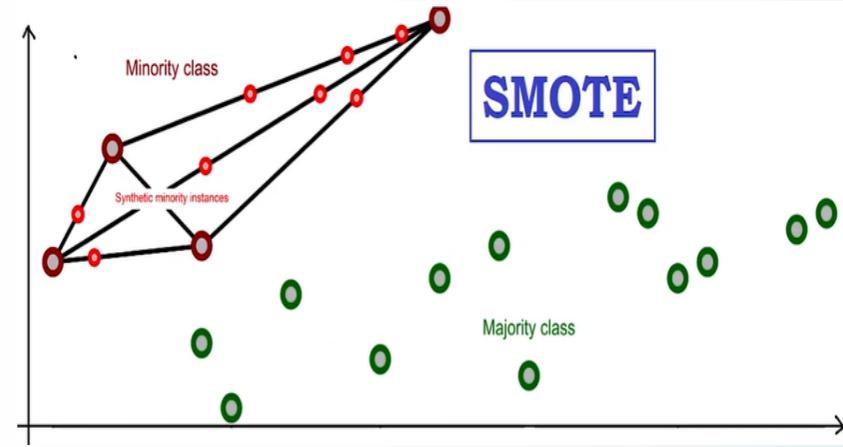
# Cách xử lý

## Ưu điểm (Advantages)

- Giảm thiểu vấn đề overfitting do random oversampling gây ra, vì các mẫu tổng hợp (synthetic samples) được tạo ra thay vì chỉ sao chép lại các mẫu có sẵn.
- Không làm mất thông tin hữu ích.

## Nhược điểm (Disadvantages)

- Khi tạo ra các mẫu tổng hợp, SMOTE không xét đến các mẫu lân cận thuộc lớp khác. Điều này có thể làm tăng sự chồng lấn giữa các lớp và có thể gây thêm nhiễu cho dữ liệu.
- SMOTE không thực sự hiệu quả với dữ liệu có số chiều cao (high-dimensional data).

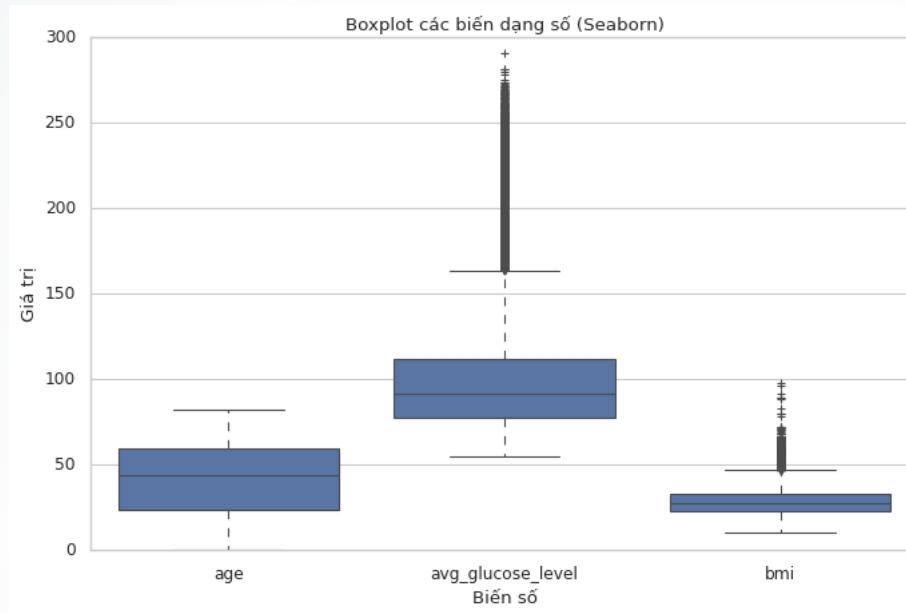


Hình 23: SMOTE

# Pre-Proccesing

Bỏ cột "ID"

Bỏ Out Layer



Hình 24: Biểu đồ Boxplot của các biến Numeric

# Pre-Proccesing

Bảng 3: Dữ liệu sau khi loại bỏ OutLayer

<b>gender</b>	0
<b>age</b>	0
<b>hypertension</b>	0
<b>heart_disease</b>	0
<b>ever_married</b>	0
<b>work_type</b>	0
<b>Residence_type</b>	0
<b>avg_glucose_level</b>	0
<b>bmi</b>	140
<b>smoking_status</b>	12043
<b>stroke</b>	0

# Pre-Processing

## Xử lý Feature "BMI"

Bỏ các giá trị thiếu có nhãn là 0

Điền các giá trị còn lại theo phân phối xác suất

Bảng 4: Sau khi xử lý

	gender	age	hypertension	heart_disease	ever_married	work_type	Residence_type	avg_glucose_level	bmi	smoking_status	stroke
36240	Female	1.88	0	0	No	children	Urban	101.41	16.9	NaN	0
13214	Male	13.00	0	0	No	children	Rural	85.40	26.3	NaN	0
1648	Female	23.00	0	0	No	Private	Rural	92.26	17.1	NaN	0

# Pre-Processing

Chia "Train" và "Test"

Bảng 5: Chia Dataset

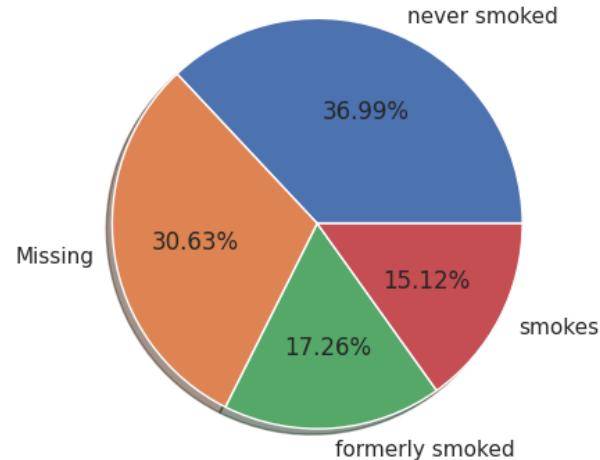
Data	Kích thước
Train	75%
Test	25%

# Pre-Processing

## Xử lý Feature "smoking\_status"

- Loại bỏ hoàn toàn thuộc tính "smoking\_status"
- Thay thế giá trị "Unknown" bằng giá trị ngẫu nhiên dựa theo phân phối thực tế
- Thay thế giá trị "Unknown" bằng giá trị ngẫu nhiên nhưng KHÔNG giữ phân phối
- Điền giá trị phổ biến nhất (Mode Imputation)

Smoking Status Pie Chart (Including Missing Values)



Hình 25: Tương quan dữ liệu ở feature "smoking\_status"

# Pre-Processing

## Xử lý Feature "Gender"

Bỏ các sample có giá trị "Other" trong cột "gender"

Bảng 6: Label feature "gender"

gender	Dạng số
Male	1
Female	0

## Xử lý Feature "Ever\_married:"

Bảng 7: Label encoder "ever\_married"

Ever_married	Dạng số
No	0
Yes	1

# Pre-Processing

## Xử lý Feature "Work type"

Do công việc children cũng là never\_worked nên có thể chuyển thành Never\_Worked

Bảng 8: One hot "work\_type"

gender	Dạng số			
work_type_Never_worked	1	0	0	0
work_type_Private	0	1	0	0
work_type_Self-employed	0	0	1	0
Govt_job	0	0	0	1

## Xử lý Feature "Residence\_type"

Bảng 9: One hot "Residence\_type"

Residence_type	Dạng số
Rural	0
Urban	1

# Pre-Processing

## Xử lý Feature "Smoking\_status"

Bảng 10: One hot "work\_type"

Smoking_status	Dạng số		
never smoked	1	0	0
smokes	0	1	0
formerly smoked	0	0	1

Các Feature còn lại ("avg\_glucose\_level", "bmi", "age"):

Dùng MinmaxScaler

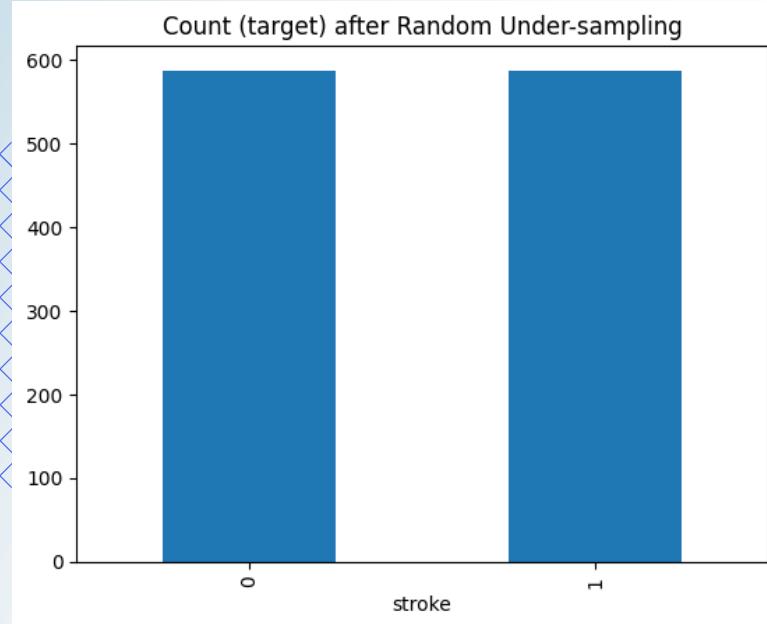
$$x' = \frac{(x - x_{min})}{(x_{max} - x_{min})}$$

# Pre-Proccesing

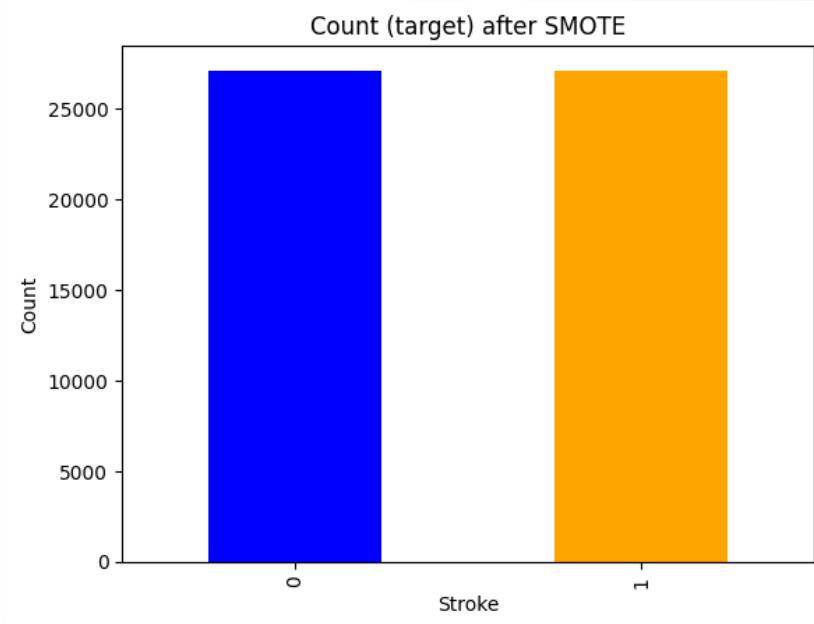
Bảng 11: One hot “work\_type”

gender	age	hypertension	heart_disease	ever_married	Residence_type	avg_glucose_level	bmi	stroke	Never_worked	Private	Self-employed	never smoked	smokes
0	0.021973	0	0	0	1	0.214128	0.146237	0	1	0	0	1	0
0	0.279785	0	0	0	0	0.171911	0.150538	0	0	1	0	0	1
0	0.426270	0	0	1	0	0.384654	0.615054	0	0	1	0	1	0

# Handel Sampling

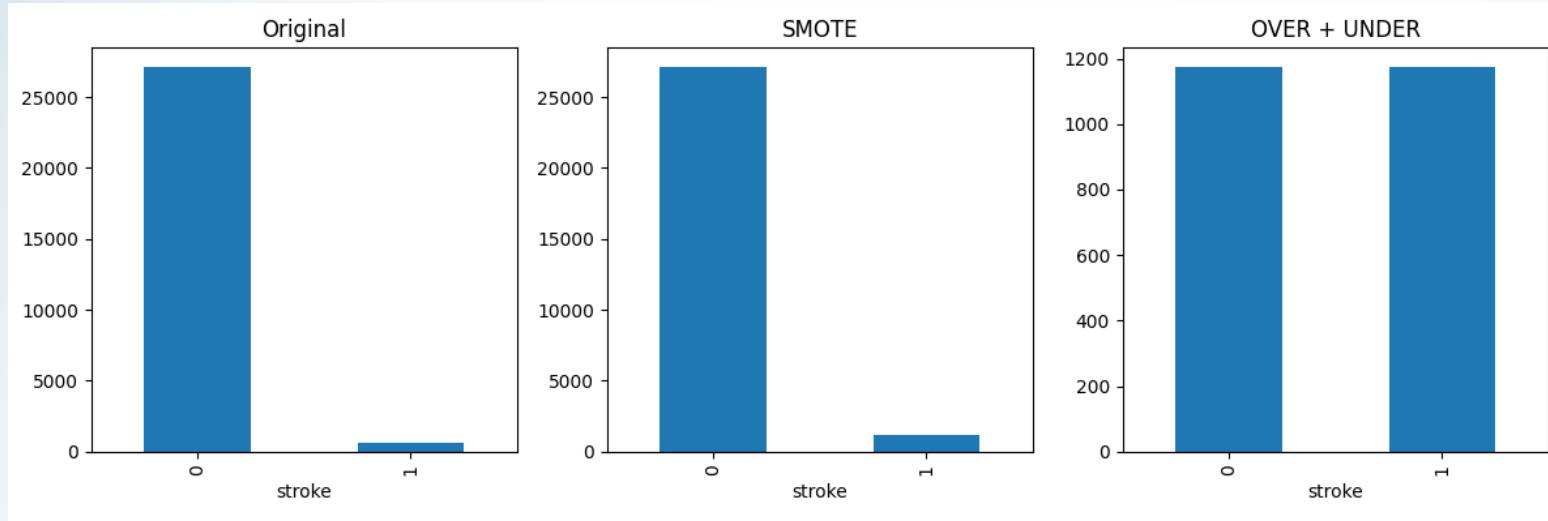


Hình 26: One hot “work\_type”



Hình 27: One hot “work\_type”

# Handel Sampling



Hình 28: One hot “work\_type”

04

## Result

# Kết quả - Riêng

## Phương pháp 1:

Bảng 12: Kết quả áp dụng Phương pháp 1

Mô hình	Sampling method	Accuracy	Precision		Recall		F1	
			0	1	0	1	0	1
Logistic Regression	Under	0.7782	0.9954	0.0895	0.7761	0.8599	0.8722	0.1622
Logistic Regression	Over	0.7790	0.9948	0.0882	0.7774	0.8408	0.8728	0.1596
SVM	Under	0.7631	0.9957	0.0853	0.7603	<u>0.8726</u>	0.8622	0.1553
SVM	Over	0.7695	0.9947	0.0848	0.7677	0.8408	0.8666	0.1540
Random Forest	Under	0.7881	0.9957	0.0939	0.7861	0.8662	0.8785	0.1695
Random Forest	Over	0.9062	0.9891	0.1525	0.9139	0.6051	0.9500	0.2436

# Kết quả - Riêng

## Phương pháp 2:

Bảng 13: Kết quả áp dụng Phương pháp 2

Mô hình	Sampling method	Accuracy	Precision		Recall		F1	
			0	1	0	1	0	1
Logistic Regression	Under	0.7869	0.9965	0.0809	0.7850	0.8724	0.8782	0.1481
Logistic Regression	Over	0.7825	0.9966	0.0798	0.7805	0.8776	0.8754	0.1463
SVM	Under	0.7682	0.9973	0.0770	0.7653	<b>0.9031</b>	0.8660	<b>0.1419</b>
SVM	Over	0.7754	0.9964	0.0770	0.7733	0.8724	0.8708	0.1416
Random Forest	Under	0.7953	0.9971	0.0856	0.7932	0.8929	0.8835	0.1562
Random Forest	Over	0.8885	0.9912	0.1146	0.8940	0.6327	0.9401	0.1941

# Kết quả - Riêng

## Phương pháp 3:

Bảng 14: Kết quả áp dụng Phương pháp 3

Mô hình	Sampling method	Accuracy	Precision		Recall		F1	
			0	1	0	1	0	1
Logistic Regression	Under	0.7862	0.9968	0.0815	0.7841	0.8827	0.8778	0.1491
Logistic Regression	Over	0.7907	0.9965	0.0823	0.7889	0.8724	0.8806	0.1503
SVM	Under	0.7648	0.9972	0.0760	0.7618	0.9031	0.8638	0.1401
SVM	Over	0.7847	0.9963	0.0797	0.7829	0.8673	0.8768	0.1460
Random Forest	Under	0.7856	0.9970	0.0820	0.7832	0.8929	0.8773	0.1502
Random Forest	Over	0.9064	0.9902	0.1272	0.9135	0.5816	0.9503	0.2088

# Kết quả - Riêng

## Phương pháp 4:

Bảng 15: Kết quả áp dụng Phương pháp 4

Mô hình	Sampling method	Accuracy	Precision		Recall		F1	
			0	1	0	1	0	1
Logistic Regression	Under	0.7884	0.9968	0.0822	0.7863	0.8827	0.8791	0.1504
Logistic Regression	Over	0.7911	0.9962	0.0816	0.7896	0.8622	0.8809	0.1491
SVM	Under	0.7685	0.9971	0.0767	0.7657	<b>0.8980</b>	0.8662	0.1414
SVM	Over	0.7878	0.9962	0.0804	0.7862	0.8622	0.8789	0.1471
Random Forest	Under	0.7958	0.9965	0.0842	0.7941	0.8724	0.8839	0.1535
Random Forest	Over	0.9105	0.9904	0.1346	0.9175	0.5918	0.9526	0.2193

# Kết quả - Kết hợp

Bảng 16: Kết quả áp dụng Phương pháp 1 - 2

Mô hình	Phương pháp	Accuracy	Precision		Recall		F1	
			0	1	0	1	0	1
Logistic Regression	1	0.7870	0.9933	0.0900	0.7867	0.8000	0.8780	0.1617
Logistic Regression	2	0.8086	0.9954	0.0855	0.8083	<u>0.8265</u>	0.8921	0.1549
SVM	1	0.7761	0.9937	0.0870	0.7752	0.8125	0.8709	0.1571
SVM	2	0.7967	0.9952	0.0804	0.7962	0.8214	0.8846	0.1464
Random Forest	1	0.8164	0.9932	0.1019	0.8172	0.7875	0.8966	0.1805
Random Forest	2	0.8282	0.9950	0.0926	0.8287	0.8061	0.9043	0.1661

# Kết quả - Kết hợp

Bảng 17: Kết quả áp dụng Phương pháp 3 - 4

Mô hình	Phương pháp	Accuracy	Precision		Recall		F1	
			0	1	0	1	0	1
Logistic Regression	3	0.8078	0.9956	0.0860	0.8071	0.8367	0.8915	0.1560
Logistic Regression	4	0.8088	0.9956	0.0864	0.8081	<u>0.8367</u>	0.8921	<u>0.1566</u>
SVM	3	0.7948	0.9950	0.0792	0.7943	0.8163	0.8834	0.1445
SVM	4	0.7950	0.9954	0.0806	0.7942	0.8316	0.8835	0.1469
Random Forest	3	0.8250	0.9952	0.0920	0.8252	0.8163	0.9023	0.1653
Random Forest	4	0.8238	0.9949	0.0904	0.8242	0.8061	0.9015	0.1626

# Kết quả

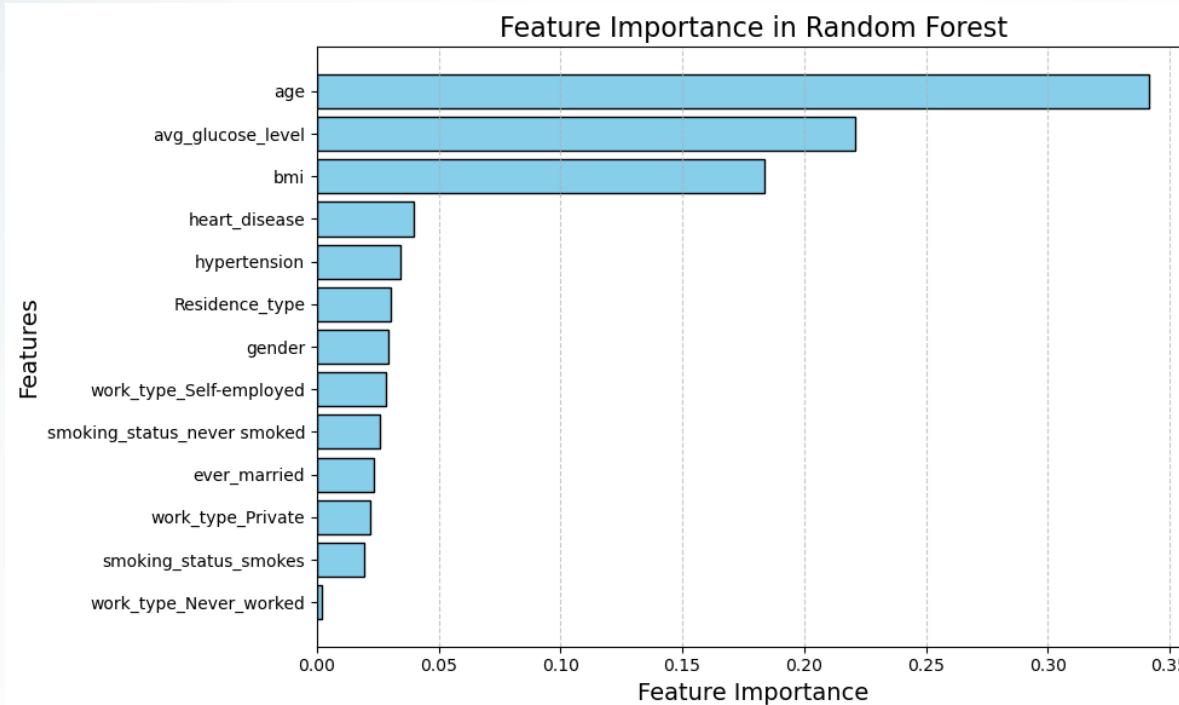
Phương pháp 2 tốt nhất:

Bảng 18: Kết quả tốt nhất

Mô hình	Sampling method	Accuracy	Precision		Recall		F1	
			0	1	0	1	0	1
Logistic Regression	Under	0.7869	0.9965	0.0809	0.7850	0.8724	0.8782	0.1481
Logistic Regression	Over	0.7825	0.9966	0.0798	0.7805	0.8776	0.8754	0.1463
SVM	Under	0.7682	0.9973	0.0770	0.7653	<b>0.9031</b>	0.8660	<b>0.1419</b>
SVM	Over	0.7754	0.9964	0.0770	0.7733	0.8724	0.8708	0.1416
Random Forest	Under	0.7953	0.9971	0.0856	0.7932	0.8929	0.8835	0.1562
Random Forest	Over	0.8885	0.9912	0.1146	0.8940	0.6327	0.9401	0.1941

# Kết quả

## Feature Importance



Hình 29: Feature Importance

# Tài liệu tham khảo

- [1] [Kiến thức Y khoa | Đột Quy Não Và Dấu Hiệu Nhận Biết Sớm Đột Quy Não](#)
- [2] [Nguyên Nhân Khiến Tỷ Lệ Đột Quy Ngày Càng Trẻ Hóa?](#)
- [3] [Logistic Regression là gì? Ví dụ bài toán Logistic Regression in Python](#)
- [4] [What is a Support Vector Machine? - Datatron](#)
- [5] [Random Forest - Regression and Classification - Explained using Sklearn - Python | INFO ARYAN](#)
- [6] [Tìm hiểu về Confusion matrix trong Machine Learning? - Viblo](#)
- [7] [FAKE AND REAL](#)
- [8] [What Is Undersampling? | Master's in Data Science](#)

# Thanks

Do you have any questions?

[hieuleduonghy@gmail.com](mailto:hieuleduonghy@gmail.com)

